

Minimisation de Consommation d'Energie pour Tâches Temps Réels Parallèles sur Architectures Multicœurs Hétérogènes

Houssam Eddine ZAHAF

Directeurs de thèse:

Richard Olejnik
Abou El Hassan Benyamina

Plan

- 1 Contexte & motivations
- 2 Les modèles de temps et d'énergie
- 3 L'allocation des tâches CPM sur des architectures hétérogènes
- 4 La modélisation des tâches parallèles par les digraphes
- 5 Conclusion & perspectives

Plan

- 1 Contexte & motivations
- 2 Les modèles de temps et d'énergie
- 3 L'allocation des tâches CPM sur des architectures hétérogènes
- 4 La modélisation des tâches parallèles par les digraphes
- 5 Conclusion & perspectives


Introduction : Systèmes cibles



Le véhicule autonome

- Traiter une grande quantité de données.
- Exprimer un parallélisme intra-tâche.
- Contraintes :
 - Temps réel
 - Energie

Introduction : Systèmes cibles



Le véhicule autonome


- Traiter une grande quantité de données.
- Exprimer un parallélisme intra-tâche.
- Contraintes :
 - Temps réel
 - Energie

Introduction : Systèmes temps réels

- Les résultats doivent être corrects **logiquement** et délivrés à **temps**.
 - Délivrés à temps \neq le plus rapide
- Les tâches temps réels sont récurrentes

Introduction : Systèmes temps réels


- Les résultats doivent être corrects **logiquement** et délivrés à **temps**.
 - Délivrés à temps \neq le plus rapide
- Les tâches temps réels sont récurrentes



Le modèle de Liu and Layland


Ordonnancement temps réel EDF-Partitionné

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu




Ordonnancement temps réel EDF-Partitionné

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu




Ordonnancement temps réel EDF-Partitionné

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu




Ordonnancement temps réel EDF-Partitionné

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu




Ordonnancement temps réel EDF-Partitionné

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu




Ordonnancement temps réel EDF-Partitionné

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu




Ordonnancement temps réel EDF-Partitionné

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu




Ordonnancement temps réel EDF-Partitionné

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu




Un ordonnanceur EDF-partitionné parallèle

- On a 3 tâches à allouer sur 2 cœurs.
- Algorithme d'ordonnancement : Earliest Deadline First.
- Allocation : $\tau_1, \tau_3 \Rightarrow$ cœur jaune, $\tau_2 \Rightarrow$ cœur bleu
- “Enlever” 2 unités de temps de τ_3 et les allouer sur le cœur bleu



Parallélisation et la sélection de fréquence

Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2, 2, 5 sur des coeurs qui opèrent à la vitesse $s = 1$



Puissance \propto fréquence³

Parallélisation et la sélection de fréquence


Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2, 2, 5 sur des cœurs qui opèrent à la vitesse $s = 1$



Puissance \propto fréquence³

Parallélisation et la sélection de fréquence


Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2, 2, 5 sur des cœurs qui opèrent à la vitesse $s = 1$



$$\text{Puissance} \propto \text{fréquence}^3$$

Parallélisation et la sélection de fréquence


Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2, 2, 5 sur des cœurs qui opèrent à la vitesse $s = 1$



Puissance \propto fréquence³

Parallélisation et la sélection de fréquence


Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2, 2, 5 sur des cœurs qui opèrent à la vitesse $s = 1$



Puissance \propto fréquence³

Parallélisation et la sélection de fréquence


Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2, 2, 5 sur des cœurs qui opèrent à la vitesse $s = 1$



$$\text{Puissance} \propto \text{fréquence}^3$$

Parallélisation et la sélection de fréquence


Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2,2,5 sur des coeurs qui opèrent à la vitesse $s = 0.75$



Puissance \propto fréquence³

Parallélisation et la sélection de fréquence


Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2,2,5 sur des coeurs qui opèrent à la vitesse $s = 0.75$



$$\text{Puissance} \propto \text{fréquence}^3$$

Parallélisation et la sélection de fréquence


Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2,2,5 sur des coeurs qui opèrent à la vitesse $s = 0.50$



$$\text{Puissance} \propto \text{fréquence}^3$$


Parallélisation et la sélection de fréquence

Soit τ une tâche qui peut être décomposée en 3 threads Th_1, Th_2, Th_3 , qui ont des temps d'exécution de 2,2,5 sur des coeurs qui opèrent à la vitesse $s = 0.35$



Puissance \propto fréquence³

Contributions



Contributions

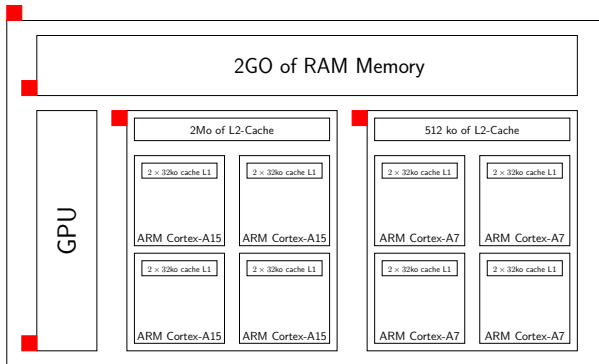
- L'interaction entre fréquence, temps d'exécution et énergie
- La modélisation du parallélisme de tâches temps réel par les cut-points
- Expression du comportement dynamique des tâches temps réel parallèles par les digraphes

Plan

- 1 Contexte & motivations
- 2 Les modèles de temps et d'énergie
- 3 L'allocation des tâches CPM sur des architectures hétérogènes
- 4 La modélisation des tâches parallèles par les digraphes
- 5 Conclusion & perspectives


Performances d'une plateforme hétérogène

- **But** : Concevoir un modèle de “temps” et de consommation d'énergie
 - Exécuter différentes tâches récurrentes avec des priorités temps réel sur une architecture hétérogène.




Modèle de temps d'exécution

■ Un thread sur un cœur little



Modèle de temps d'exécution

- Un thread sur un cœur little




- Le temps d'exécution est une fonction de la tâche et de la fréquence
- Régression non-linéaire :
$$C(f_{op}) = \frac{Const_1}{f_{op}} + Const_2$$

Le modèle de temps d'exécution

- La taille des données traitées est changée


$$C(f_{op}) = \frac{Const_1}{f_{op}} + Const_2$$



- $Const_2$ représente le temps d'accès mémoire

Le modèle de puissance


- Un thread par cœur



- La puissance dissipée dépend de la tâche

Le modèle de la puissance : Régression VS valeurs réelles


- Régression polynomiale de 3^e degré est appliquée
- La régression est très exacte




- La puissance dissipée par 2 threads n'est pas $\times 2$ la puissance dissipée par 1 thread.

Le modèle de puissance : La mémoire

- Quand un thread est alloué sur un cœur little, la mémoire consomme plus que s'il est alloué sur un cœur big
 - Cache-L2 plus petit \Rightarrow plus cache-miss \Rightarrow plus d'accès mémoire.
- La mémoire consomme plus que 20% de la consommation totale d'un cœur little



Le modèle d'énergie



- Augmenter la fréquence “peut” aider à réduire la consommation d'énergie jusqu'à une certaine fréquence (*effective*).
- La fréquence effective varie d'une tâche à une autre

Que retenir de ces expérimentations

La puissance dissipée dépend :

- Du type du coeur où la tâche est allouée
- De la fréquence du coeur
- De la tâche elle-même

Quelques remarques :

- Deux threads de la même tâche dissipent la même puissance.
- L'énergie statique dépend du voltage qui peut dépendre de la fréquence.
- La consommation d'énergie de la mémoire est importante.
- La fréquence effective est propre à chaque tâche.

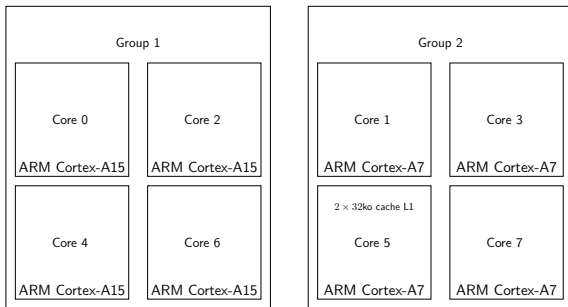
Plan

- 1 Contexte & motivations
- 2 Les modèles de temps et d'énergie
- 3 L'allocation des tâches CPM sur des architectures hétérogènes
- 4 La modélisation des tâches parallèles par les digraphes
- 5 Conclusion & perspectives

Le modèle d'architecture

Une architecture hétérogène est modélisée par :

- Un ensemble de G groupes
- Chaque groupe $g \in G$ est composé d'un ensemble de coeurs
- Les coeurs du même groupe opèrent sur la même fréquence.



Modèle de tâches

Modèle de tâches




$$\mathcal{C}(f_{op}) = \frac{\text{Const}_1}{f_{op}} + \text{Const}_2$$

Modèle de tâches




$$\mathcal{C}(f_{op}) = \frac{\text{Const}_1}{f_{op}} + \text{Const}_2$$

Modèle de tâches




$$C(f_{op}) = \frac{\text{Const}_1}{f_{op}} + \text{Const}_2$$

Modèle de tâches




$$\mathcal{C}(f_{op}) = \frac{\text{Const}_1}{f_{op}} + \text{Const}_2$$

Modèle de tâches




$$\mathcal{C}(f_{op}) = \frac{\text{Const}_1}{f_{op}} + \text{Const}_2$$

Modèle de tâches




$$C(f_{op}) = \frac{\text{Const}_1}{f_{op}} + \text{Const}_2$$

Modèle de tâches



$$\mathcal{C}(f_{op}) = \frac{\text{Const}_1}{f_{op}} + \text{Const}_2$$

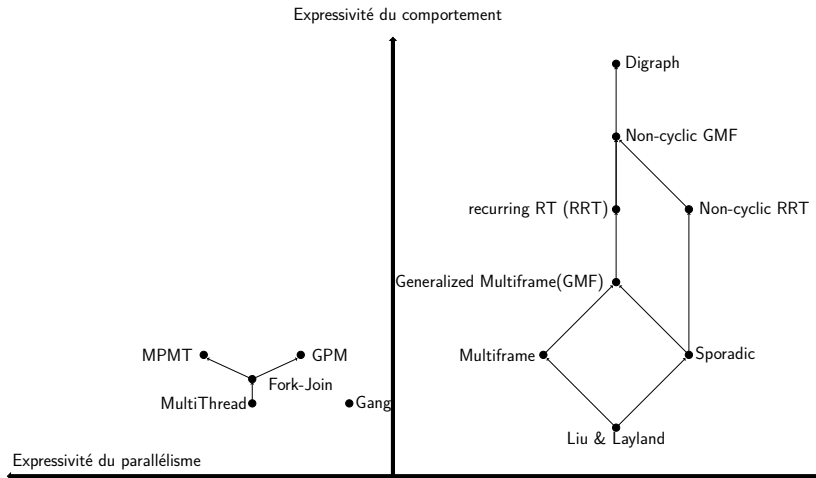
Modèle de tâches



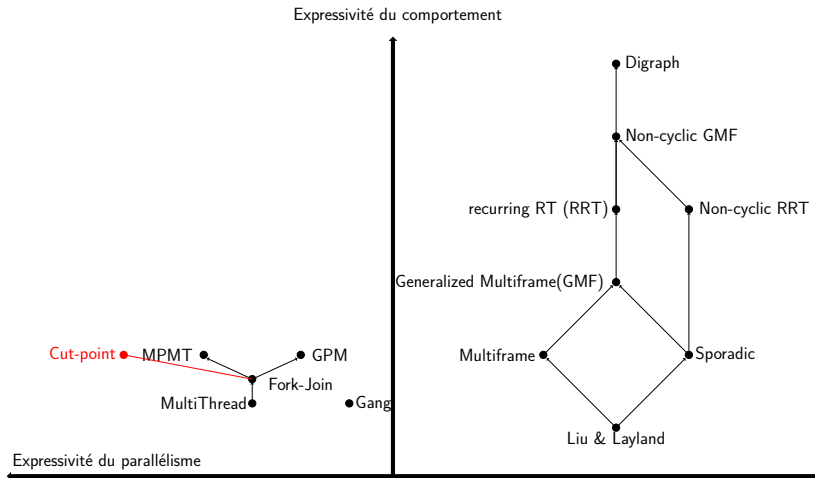
$$\mathcal{C}(f_{op}) = \frac{\text{Const}_1}{f_{op}} + \text{Const}_2$$

- Le temps d'exécution de chaque thread est caractérisé par : $\text{Const}_1^g, \text{Const}_2^g$
- $\sum_z C_{i,k,z} \geq C_{i,1,1}, \forall i, k$
- \vec{e} un vecteur des coefficients du polynômes de la consommation d'énergie

Modèle cut-point et modèles de tâches



Modèle cut-point et modèles de tâches



Problème à résoudre

Nous avons :

- Un ensemble de tâches modélisées par CPM.
- Une plateforme avec un ensemble de coeurs hétérogènes

Objectif

- Allouer les tâches aux coeurs
- Sélectionner la fréquence minimale en hors-ligne pour chaque groupe.

Contraintes

- Toutes les échéances doivent être respectées.

Solution Exacte : INLP

- Partitionné : migration difficile à gérer
- Solution exacte : énumération des combinaisons par la programmation en nombre entier

Formulation en INLP

- $x_{i,j,k,z}$ définit l'allocation du thread $Th_{i,k,z}$ au coeur j
- f^g la fréquence opérationnelle du groupe g
- La fonction objectif est non-linéaire : $minE = \dots x_{i,j,k,z} \frac{C_{i,k,z}}{f^g} \dots$



Exemple : 5 tâches, 5 cut-points , 8 threads, 8 coeurs, hyper period = 1000 → 2 568 038 contraintes

Pas facile à résoudre

La résolution peut prendre plusieurs heures pour un problème de petite taille.



L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.





L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.





L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.





L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.





L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.





L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.





L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.





L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.




L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.




L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.




Threads maintenus d'un point de vue temps réel




L'heuristique de partitionnement

- Définir le maximum de temps d'exécution d'une tâche qui peut être alloué à un processeur
- **Exemple** : Th_1, Th_2 sont deux threads alloués à un processeur et on essaye d'allouer τ (à droite) sur le même processeur.



Threads maintenus d'un point de vue temps réel



Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}} nb$


Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}} nb$



Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}}$ nb



Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}}$ nb



Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}}$ nb



Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}^g} nb$



Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}^g} nb$



Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}} nb$



Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}^g} nb$




Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}^g} nb$





Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}} nb$

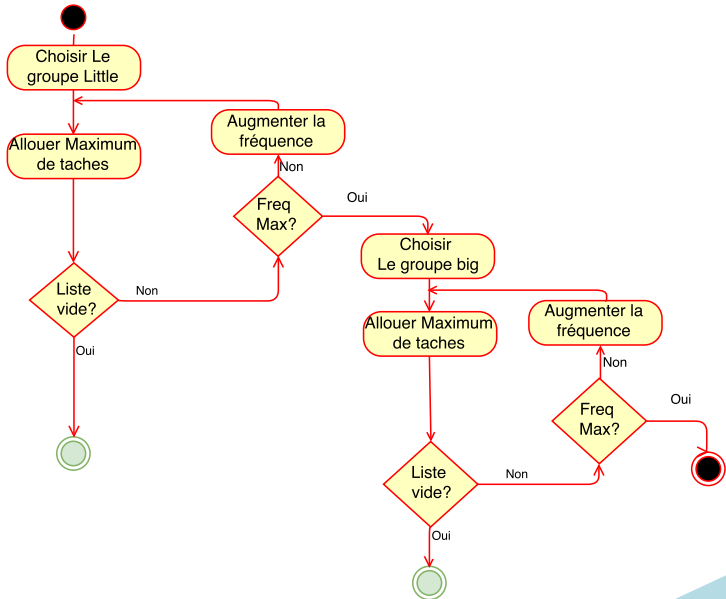


Sélection de fréquence

- La fréquence est entre la fréquence effective minimale et la fréquence max
- La puissance de calcul est définie comme $\frac{f_{op}^g}{f_{max}} nb$



Algorithme global




Protocole expérimental

- Plateforme hétérogène simulée : Exynos 5422.
- Utilisation générée (les coeurs littles comme référence) de 0.5 à 18.
- Comparer contre les heuristiques séquentielles Best Fit (BF), First Fit (FF), Worst Fit (WF)



Scénarios :

- Utilisation : $u_i = \frac{C_{i11}}{T_i} \leq 1$,
- Utilisation : $u_i = \frac{C_{i11}}{T_i}$ peut être > 1





Scénario 1





Scénario 1



Scénario 1



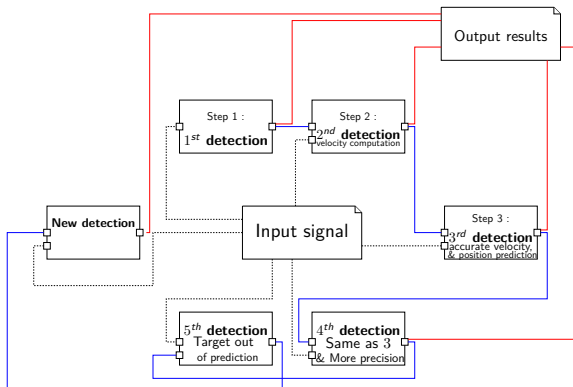
Scénario 1



Plan


- 1 Contexte & motivations
- 2 Les modèles de temps et d'énergie
- 3 L'allocation des tâches CPM sur des architectures hétérogènes
- 4 La modélisation des tâches parallèles par les digraphes
- 5 Conclusion & perspectives

Radar MTI



- Le traitement dépend de la valeur des données en entrée
- Le traitement à faire est parallélisable

Une tâche parallèle avec digraphe



Une tâche est :

- Sporadique (échéance contrainte $D_i \leq T_i$)
- Modélisée par un *automate*

Chaque état :

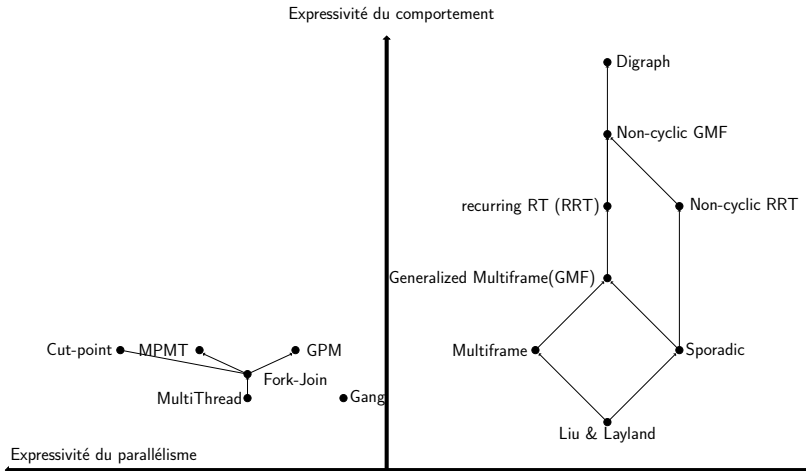
- est une instance de la tâche
- composée de threads.

La transition entre états :

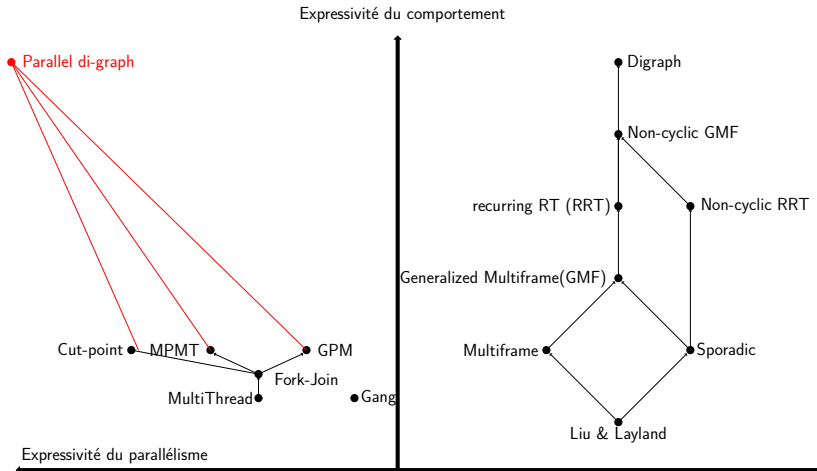
- Précédence entre deux instances.
- Non-déterministe

FIGURE : τ_i digraphe, $D_i = 10, T_i = 12$

Les modèles de tâches



Les modèles de tâches



Formulation du problème

Nous avons :

- Un ensemble de tâches digraphes
- Un ensemble de coeurs identiques qui opèrent sur la même fréquence variable.

Objectif

- Allouer les digraphes sur les coeurs
- Sélectionner la fréquence minimale


Contraintes

- Toutes les échéances doivent être respectées

Uniprocasseur

Uniprocasseur

Soit \mathcal{T} un ensemble de tâches, et t un entier positif. \mathcal{T} est ordonnançable sous EDF si et seulement si : (Stigge et al.). $\forall t, \text{dbf}(\mathcal{T}, t) \leq t$



Pour calculer la $\text{dbf}(\mathcal{T}, t)$:

- 1 Calculer la df pour tous les chemins, pour chaque tâche $\tau_i \in \mathcal{T}$
- 2 Pour chaque tâche et chemin, choisir la maximum df pour toutes les valeurs de t
- 3 Additionner les résultats du 2.

Partitionnement des digraphes

- EDF-partitionné.



Solution Exacte

Vérifier la combinaison de toutes les tâches, états, threads, sur tous les coeurs et toutes les fréquences.



Pour chaque processeur et chaque tâche :

- 1 Essayer d'allouer La tâche en séquentiel.
- 2 Si non, elle est décomposée en deux parties :
 - La première partie est allouée au coeur courant
 - La deuxième est remise à la liste de tâches non allouées.



Partitionnement :





Partitionnement :





Partitionnement :





Tâche équivalente avec un thread



Tâche équivalente avec un thread





Tâche équivalente avec un thread





- Il s'agit de la conversion du modèle digraphe en modèle périodique de Liu et Layland.



Partitionnement





Partitionnement



Partitionnement






Partitionnement



Un exemple de décomposition

Supposons que :

- $\text{excess} = 3$.
- la tâche à décomposer est :



Algorithme d'allocation

La sélection de fréquence



L'algorithme de sélection de fréquence est un algorithme glouton :

- 1 Sélectionner une fréquence
- 2 Vérifier l'ordonnançabilité
- 3 Si le test échoue, augmenter la fréquence, si non succès



Protocole expérimental

- La plateforme contient 4 coeurs
- Utilisation totale variée entre 0.5 et 4 par saut de 0.5
- Comparer contre :
 - Le modèle séquentiel de Liu et Layland (Seq-periodic)
 - Une parallélisation de Liu and Layland (Par-periodic)
 - Le modèle séquentiel de digraphe (Seq-di-graph)
- Scénarios :
 - Petite variabilité d'un état à un autre (± 0.1)
 - Grande variabilité d'un état à un autre (± 0.3)


Le taux d'ordonnançabilité : S_1 vs S_2



Minimisation de vitesse : S1 vs S2



Minimisation de consommation d'énergie : S2



Plan

- 1 Contexte & motivations
- 2 Les modèles de temps et d'énergie
- 3 L'allocation des tâches CPM sur des architectures hétérogènes
- 4 La modélisation des tâches parallèles par les digraphes
- 5 Conclusion & perspectives

Conclusion

J'ai proposé :

- Un modèle de temps et de consommation d'énergie basé sur des benchmarks sur une plateforme hétérogène.
- Deux modèles de tâches réalistes :
 - Le modèle CPM : modélise une tâche parallèle par un ensemble de cut-points.
 - Le modèle digraphe : modélise une tâche parallèle par un digraphe
- Deux tests d'ordonnançabilité ont été proposés pour analyser les modèles.

Perspectives

- Implanter les modèles proposés sur un API comme OpenMP
- Étendre le modèle digraphe avec des inter-arrivals et échéances arbitraires (travail en cours)
- Fusionner le modèle CPM et digraphe pour faire un modèle très expressif.
- Introduire le changement dynamique de la fréquence au problème.
- Utiliser les approximations de dbf pour réduire la complexité du modèle INLP

Travail scientifique

- H.E. Zahaf et al. "Modelling parallel task with Di-Graphs", RTNS'2016, Brest France, 19-21/10,2016.
- H.E. Zahaf et al. "Energy-Efficient Scheduling for Moldable Real-Time Tasks on Heterogeneous Computing Platforms", Under Revision Journal Of System Architecture
- H.E. Zahaf et al. "Modelling the Energy Consumption of Soft Real-Time Tasks on Heterogeneous Computing Architectures", EEHCO'2016, prague, January 15-16, 2016
- H.E. Zahaf, R. Olejnik, G. Lipari, A.E Benyamina , "Energy-aware moldable real-time task scheduling on uniform architectures", EDiS'2015, November 15-16, 2015
- H.E. Zahaf et al. "Intensive Real-Time Task Scheduling on Uniform Multiprocessors", (MOMA Journal), Vol 2, Issue 12014, Pages 3-13,
- H.E. Zahaf, A.E. Benyamina, R. Olejnik "Intensive Real-Time Task Scheduling on Uniform Multiprocessors",The 2 nd international Workshop on Mathamatics and Computer Science IWMCS'2014, december 1-3, 2014, Tiaret, Algeria.